

沈颖涛

男 | 2000 年 1 月 19 日生 | 籍贯：浙江杭州

电话/微信: (+86) 158-6822-3612 | doctorcoal@sjtu.edu.cn | 上海交通大学 浦江国际学院 (原密西根学院)

研究方向：端侧 AI 轻量化 | Base 初步意向：上海，杭州

教育经历

上海交通大学 电子科学与技术 硕博连读	2022.09 - 2027.06 (预计)
高效计算硬件与系统实验室 (ECHSL) 导师：邹校 副教授	
上海交通大学 电子与计算机工程 理学学士	2018.09 - 2022.06
GPA: 3.55/4.00 (排名: 27/151) 毕业设计：FPGA 平台上矩阵乘法的并行化与近似计算优化	

论文发表

- ACL 2026 (CCF-A 会议, 第一作者)** Yingtao Shen, An Zou. "River-LLM: Large Language Model Seamless Exit Based on KV Share." *ACL 2026*.
提出免训练的解码式大语言模型词元级无缝提前退出框架, 以 KV 共享退出支流消除昂贵的缓存恢复开销, 使 Ministral3, Phi4, Llama3 等模型在数学推理与代码生成任务上实现 $1.71\times-2.16\times$ 实际时钟加速。
- DATE 2026 (CCF-B 会议, Oral, 第一作者)** Yingtao Shen, Yinchun Ni, Jiace Zhu, Jie Zhao, An Zou. "Compression Space Search: RL-based Combinational Compression for Neural Networks." *DATE 2026*.
将量化, 剪枝, 知识蒸馏, 早期退出等多种模型压缩和优化方法的选型、顺序与程度建模为马尔可夫决策过程, 以强化学习自动搜索最优组合压缩策略, 突破单一压缩方法的性能天花板。在 CNN 与 ViT 上实现最高 100.8 倍理论加速; 在 Jetson AGX Orin 上, 比起 TensorRT 充分优化的原模型, 仍有 $2.0-5.2$ 倍推理加速和 $3.3-5.4$ 倍显存节省。
- IEEE TCAD 2025 (CCF-A 期刊, 第一作者)** Yingtao Shen, Xiangjie Li, Yehan Ma, Jie Zhao, An Zou. "LEAP: Light Weighting Neural Network Inference through Proactive Early Exiting Prediction." *IEEE TCAD 2025*.
提出主动式早期退出预测机制, 以低开销预测引擎在推理早期预判最优计算深度, 对 CNN 与 ViT, 在 Jetson AGX Orin 和 i7-10700 上能耗降低 83% , 时延降低 71% , 精度损失 1% 以内。
- DAC 2023 (CCF-A 会议, Oral, 共同第一作者)** Xiangjie Li*, Yingtao Shen*, An Zou, Yehan Ma. "EENet: Energy Efficient Neural Networks with Run-time Power Management." *DAC 2023*.
将动态提前退出与处理器运行时功耗管理 (DVFS) 协同设计, 实现神经网络推理能耗-性能的联合优化。在降低 ResNet 64% 能耗的同时, 实时性超越领域 SOTA 方法。
- IEEE TCAD 2026 (CCF-A 期刊)** Haolan Zhang, Jintao Chen, Yingtao Shen, An Zou, Yehan Ma. "Cheerful: Hardware-Oriented Early Exits for Ubiquitous Computing." *IEEE TCAD 2026*.
- DATE 2025 (CCF-B 会议)** Mingqing Sun, Ruiqi Sun, Yingtao Shen, Wei Yan, Qinfen Hao, An Zou. "SSMDVFS: Microsecond-Scale DVFS on GPGPUs with Supervised and Self-Calibrated ML." *DATE 2025*.
- AAAI 2023 (CCF-A 会议, Oral)** Xiangjie Li, Chenfei Lou, Zhengping Zhu, Yuchi Chen, Yingtao Shen, Yehan Ma, An Zou. "Predictive Exit: Prediction of Fine-Grained Early Exits for Computation- and Energy-Efficient Inference." *AAAI 2023*.
- CSTIC 2023 (会议, Oral, 第一作者)** Yingtao Shen, An Zou. "Learning-Based Performance and Power Model for Processor Microsecond DVFS." *CSTIC 2023*.

项目经历

智能算法轻量化设计技术研究【研究所横向】	2026.03 - 2026.09
合作单位：上海机电工程研究所 (航天八院) 项目核心成员, 负责轻量化框架与工程算法的对接	
需求：面向国防关键设备上运行的视觉智能算法的嵌入式实时推理需求, 研究自动轻量化设计技术;	
职责：将现有科研成果组合压缩框架高度模块化封装并编写接口, 完成框架与具体工程算法的对接与部署验证;	
成果：形成一套自动压缩工具链, 支持 ONNX / PyTorch / TensorFlow2 模型, 覆盖 YOLO/ResNet、DeiT、LSTM 等典型架构, 在精度损失不超过 2% 的约束下, 预计针对不同算法降低 $50-95\%$ 算力消耗和 $50-90\%$ 显存占用。	

基于强化学习的组合压缩自动化搜索框架【科研项目】

2024.09 –至今

上海交通大学 高效计算硬件与系统实验室 (ECHSL)

- 项目背景:** 现有单方法为主的模型压缩实践效果逼近边际, 组合压缩潜力巨大, 但人工设计组合压缩策略高度依赖专家经验、穷举搜索开销达到指数级;
- 算法创新:** 将压缩方法的选型、施序与程度统一建模为**马可夫决策过程**, 编写**组合压缩环境**并重新设计状态/动作/奖励函数表示, 结合无效动作掩码与路径缓存等技术, 高效发现最优组合压缩策略;
- 性能提升:** 在 ResNet、MobileNet、DeiT 等 CNN 与 ViT 及 CIFAR100、ImageNet 等数据集上测试得到约 **30-100x** 理论 BitOps 加速, 实际达成 **2-5x** 推理加速和 **3-6x** 显存优化, 成果发表于 DATE 2026 (Oral)。

面向计算与能耗高效推理的细粒度早期退出预测【科研项目】

2022.09 –2024.06

上海交通大学 高效计算硬件与系统实验室 (ECHSL)

- 项目背景:** 早期退出为动态推理的核心技术之一, 过去的被动式早期退出必须逐层执行退出层才能决策, 阻碍了系统与硬件的预先优化且带来了大量退出开销;
- 算法创新:** 提出**主动式退出预测**, 从早期层特征直接预测最优计算深度。设计低开销预测引擎(一维迭代卷积)与统一退出层, 并与处理器功耗管理与运行时调度协同设计, 实现**推理速度-能耗-精度-实时性**联合优化;
- 性能提升:** 在服务器与嵌入式 GPU 平台上, 对 ResNet34 FP32/INT8 最高达到 **83%** 能耗节省与 **2.6x** 推理加速, 成果发表于 AAAI 2023 (Oral)、DAC 2023 (Oral) 与 IEEE TCAD 2025。

交龙机器人战队 机电工程师【竞赛】

2018.11 –2020.11

- 职责:** 先后担任“步兵”组与“英雄”组负责人(约 10 人)、机械部部长(约 30 人), 管理机器人的研发和测试;
- 成果:** 主导完成“自适应悬挂”、“低惯量云台”、“高精度小弹丸发射”、“麦轮底盘攀升模块”等项目并应用于竞赛机器人, 随队获 RoboMaster 全国大学生机器人大赛总决赛特等奖。

荣誉奖项

- | | |
|---------------------------------------|---------|
| • DAC Young Fellow Award | 2023.04 |
| • 密西根学院励志奖学金 | 2023.11 |
| • RoboMaster 全国大学生机器人大赛 (RMUC) 全国一等奖 | 2020.08 |
| • 密西根学院本科卓越与学业成就奖学金 | 2020.11 |
| • 密西根学院吴炯、孙洁阳光奖学金 | 2019.11 |
| • RoboMaster 全国大学生机器人大赛 (RMUC) 总决赛特等奖 | 2019.08 |

发明专利

- 邹桢、沈颖涛、马叶涵. 基于最优组合压缩序列的神经网络模型压缩方法与系统. CN118133921A, 2024.
- 邹桢、马叶涵、沈颖涛. 基于神经网络的图像识别方法、系统、介质及设备. CN116229184A, 2023.
- 邹桢、马叶涵、沈颖涛. 针对多次连续推理的神经网络动态退出轻量化方法和系统. CN116227558A, 2023.
- 冷春涛、覃一飞、沈颖涛、武书昆、郝丽. 基于机械连杆机构的自适应悬挂底盘系统. CN111267569B, 2020.

技能与证书

- 技术栈: PyTorch、vLLM、TensorRT、ONNX | 动态推理、蒸馏、量化、剪枝(稀疏化)、低秩分解、NAS
- 编程与硬件描述语言/工具: C、C++、Python、MATLAB、Verilog、Latex、HLS (Vitis)
- 工程软件与技能: SolidWorks (CSWA 助理工程师认证)、Vivado / Vitis、Cursor/Github Copilot