沈颖涛

男 | 2000 年 1 月 19 日生 | 籍贯：浙江杭州

doctorcoal@sjtu.edu.cn | 上海交通大学 浦江国际学院（原密西根学院）

学历：27 届博士 | 研究方向：端侧 AI 轻量化 | Base 意向：上海，杭州

教育经历

上海交通大学 | 电子科学与技术 硕博连读 2022.09 –2027.06（预计）

高效计算硬件与系统实验室（ECHSL） | 导师：邹桉 副教授

上海交通大学 | 电子与计算机工程 工学学士 2018.09 –2022.06

GPA：3.55/4.00 (排名: 27/151) | 毕业设计：FPGA 平台上矩阵乘法的并行化与近似计算优化

论文发表

1. **ACL'26（CCF-A 会议，一作）** **Yingtao Shen**[Oral], An Zou. "River-LLM: Large Language Model Seamless Exit Based on KV Share."

   【动态推理;KV Cache 优化】提出免训练的解码式**大语言模型词元级无缝提前退出**框架。以 KV 共享退出支流消除昂贵的缓存恢复开销，使 Ministral3, Phi4, Llama3 等模型在数学推理与代码生成任务上实现 **1.71×–2.16×** 实际时钟加速。

2. **DATE'26（CCF-B 会议，一作）** **Yingtao Shen**[Oral], Yinchen Ni, Jiace Zhu, Jie Zhao, An Zou. "Compression Space Search: RL-based Combinational Compression for Neural Networks."

   【组合压缩】将**量化**，**剪枝**，**知识蒸馏**，**早期退出**等多种模型压缩和优化方法的选型、顺序与程度建模为马尔可夫决策过程，以强化学习自动搜索最优组合压缩策略，突破单一压缩方法的性能天花板。在 CNN 与 ViT 上实现最高 **100.8** 倍理论加速; 在 Jetson AGX Orin 上，比起 TensorRT 充分优化的原模型，仍有 **2.0-5.2** 倍推理加速和 **3.3-5.4** 倍显存节省。

3. **IEEE TCAD'25（CCF-A 期刊，一作）** **Yingtao Shen**, Xiangjie Li, Yehan Ma, Jie Zhao, An Zou. "LEAP: Light Weighting Neural Network Inference through Proactive Early Exiting Prediction."

   【动态推理】提出主动式早期退出预测机制，以低开销预测引擎在推理早期预判最优计算深度，对多种经典 CNN 与 ViT，在 i7-10700 和 Jetson TX2 上能耗降低 **83%**，时延降低 **71%**，精度损失 **1%** 以内。

4. **DAC'23（CCF-A 会议，共一）** Xiangjie Li*, **Yingtao Shen***[Oral], An Zou, Yehan Ma. "EENet: Energy Efficient Neural Networks with Run-time Power Management."

   【动态推理; 动态电压频率调节】将动态提前退出与处理器运行时功耗管理（DVFS）协同设计，实现神经网络推理能耗-性能的联合优化。在 Jetson TX2 上降低 ResNet34 **64%** 能耗的同时，实时性超越领域 SOTA 方法。

5. **IEEE TCAD'26(CCF-A 期刊,二作)** Haolan Zhang, Jintao Chen, **Yingtao Shen**, An Zou, Yehan Ma. "Cheerful: Hardware-Oriented Early Exits for Ubiquitous Computing."

6. **DATE'25（CCF-B 会议，二作）** Minqing Sun, Ruiqi Sun, **Yingtao Shen**, Wei Yan, Qinfen Hao, An Zou. "SSMDVFS: Microsecond-Scale DVFS on GPGPUs with Supervised and Self-Calibrated ML."

7. **AAAI'23(CCF-A 会议,二作)** Xiangjie Li, Chenfei Lou, Zhengping Zhu, Yuchi Chen, **Yingtao Shen**, Yehan Ma, An Zou. "Predictive Exit: Prediction of Fine-Grained Early Exits for Computation & Energy-Efficient Inference."

8. **CSTIC'23（中国半导体大会，一作）** **Yingtao Shen**[Oral], An Zou. "Learning-Based Performance and Power Model for Processor Microsecond DVFS."

项目经历

基于强化学习的组合压缩自动化搜索框架【学术】 2024.09 –至今

单位：上海交通大学 高效计算硬件与系统实验室（ECHSL） | 职务：核心研发

设计面向组合压缩的 RL 算法、环境、搜索策略 | 融合量化，剪枝，动态推理和知识蒸馏 | 100x 理论加速，5x Orin 推理加速

- **项目背景**：现有单方法为主的模型压缩实践效果逼近边际，组合压缩潜力巨大，但人工设计组合压缩策略高度依赖专家经验、穷举搜索开销达到指数级；
- **算法创新**：将压缩方法的选型、施序与程度统一建模为马可夫决策过程，编写**组合压缩环境**并重新设计状态/动作/奖励函数表示，结合无效动作掩码与路径缓存等技术，高效发现最优组合压缩策略；
- **性能提升**：在 ResNet、MobileNet、DeiT 等 CNN 与 ViT 及 CIFAR100、ImageNet 等数据集上测试得到约 **30-100x** 理论 BitOps 加速，在 Jetson AGX Orin 上实际达成 **2-5x** 推理加速和 **3-6x** 显存优化，成果发表于 DATE 2026 [2]。

人工智能轻量化压缩系统【实习】 2026.03 –2026.09

单位：上海航天 | 职务：人工智能工程师（控制、图像、信息处理）

科研成果落地 | 模块化封装和容器化运行 | 对各类涉密 CNN 与 VLM 模型架构实现 50-90% 显存节省

- **需求**：面向国防关键设备上运行的视觉等智能算法的嵌入式实时推理需求，研究自动轻量化设计技术；
- **职责**：将现有科研成果组合压缩框架高度模块化封装并编写接口，完成框架与具体工程算法的对接与部署验证；
- **成果**：**形成一套自动压缩工具链**。支持 ONNX / PyTorch / TensorFlow2 模型，覆盖 CNN、YOLO、ViT、VLM 等典型架构，在精度损失不超过 **2%** 的约束下，针对不同算法降低 **50-95%** 算力消耗和 **50-90%** 显存占用。

面向计算与能耗高效推理的细粒度早期退出预测【学术】 2022.09 –2024.06

单位：上海交通大学 高效计算硬件与系统实验室（ECHSL） | 职务：核心研发

主动式 DNN 早退预测与动态电压频率调节 软硬件协同 | 在嵌入式 CPU 与 SoC GPU 上最高 83% 能耗节省与 2.6x 推理加速

- **项目背景**：早期退出为动态推理的核心技术之一，过去的被动式早期退出必须逐层执行退出层才能决策，阻碍了系统与硬件的预先优化且带来了大量退出开销；
- **算法创新**：提出**主动式退出预测**，从早期层特征直接预测最优计算深度。设计低开销预测引擎（一维迭代卷积）与统一退出层，并与处理器功耗管理与运行时调度协同设计，实现**推理速度-能耗-精度-实时性**联合优化；
- **性能提升**：在 i7-10700 和 Jetson TX2 上，对 ResNet34 FP32/INT8 等模型最高达到 **83%** 能耗节省与 **2.6x** 推理加速，成果发表于 AAAI 2023 [7]、DAC 2023 [4] 与 IEEE TCAD 2025 [3]。

RoboMaster 竞赛机器人研发【竞赛】 2018.11 –2020.11

单位：上海交通大学 云汉交龙机器人战队 | 职务：机械部部长/机电工程师

- **职责**：先后担任 “步兵” 组与 “英雄” 组负责人（约 10 人）、机械部部长（约 30 人），管理机器人的研发和测试；
- **成果**：主导完成 “麦轮底盘自适应悬挂”、“低惯量与高精度小弹丸云台发射系统”、“麦轮底盘攀升模块” 等项目并应用于竞赛机器人，作为核心队员获 RoboMaster 全国大学生机器人大赛总决赛特等奖。

荣誉奖项

- （学术）DAC Young Fellow Award 2023.04
- （奖学金）密西根学院励志奖学金 2023.11
- （奖学金）密西根学院本科卓越与学业成就奖学金 2020.11
- （奖学金）密西根学院吴炯、孙洁阳光奖学金 2019.11
- （竞赛）RoboMaster 全国大学生机器人大赛（RMUC）对抗赛（线上）一等奖 国家级，2020.08
- （竞赛）RoboMaster 高校联盟赛（RMUL）江苏站冠军 省部级，2019.12
- （竞赛）RoboMaster 全国大学生机器人大赛（RMUC）总决赛特等奖 国家级，2019.08

发明专利

- （学术）邹桉、沈颖涛、马叶涵. 基于最优组合压缩序列的神经网络模型压缩方法与系统. CN118133921A, 2024.
- （学术）邹桉、马叶涵、沈颖涛. 基于神经网络的图像识别方法、系统、介质及设备. CN116229184A, 2023.
- （学术）邹桉、马叶涵、沈颖涛. 针对多次连续推理的神经网络动态退出轻量化方法和系统. CN116227558A, 2023.
- （竞赛）冷春涛、覃一飞、沈颖涛、武书昆、郝丽. 基于机械连杆机构的自适应悬挂底盘系统. CN111267569A, 2020.

技能与证书

- 技术栈：PyTorch、vLLM、TensorRT、ONNX | 动态推理、蒸馏、量化、剪枝（稀疏化）、低秩分解、NAS
- 编程与硬件描述语言/工具：Python、C、C++、MATLAB、Verilog、Latex、HLS（Vitis）
- 工程软件与技能：SolidWorks（CSWA 助理工程师认证）、Vivado / Vitis、Cursor/Github Copilot